doi: 10.19306/j.cnki.2095-8110.2026.03.003

线性离散系统的自适应集员滤波方法

李育东[1], 董久祥[1], 丛一睿[2]

（1. 东北大学信息科学与工程学院, 沈阳 110819;
2. 国防科技大学智能科学学院, 长沙 410073）

摘　要: 在实际工程应用中, 极端天气条件、电磁干扰及其他复杂环境干扰因素普遍存在。这些因素会引入严重的模型不确定性, 导致传统导航和估计系统因依赖精确的先验模型而出现性能退化甚至滤波发散。尤为关键的是, 此类不确定性在实际运行中往往不可测、时变且缺乏可靠的统计先验信息, 给鲁棒状态估计带来了巨大挑战。为应对这一难题, 提出了一种自适应集员滤波(ASMF)框架, 以解决在有界噪声先验信息完全未知条件下的线性离散系统状态估计这一公开问题。与依赖固定噪声边界的传统集员滤波方法不同, 本框架引入了不确定性变量进行系统建模。基于系统模型, 从测量数据序列中逐步提取测量噪声的最坏情况边界信息, 迭代学习观测噪声的未知边界, 实现对噪声特性的自适应辨识。在此基础上, 滤波器能够动态调整估计域, 逐步逼近真实状态, 实现系统状态的渐近有界跟踪。设计了基于带约束全对称多胞形的自适应滤波算法, 建立了可扩展的理论框架, 并完成了其稳定性分析。仿真实验验证了所提方法在未知干扰环境下仍具备稳定的估计性能, 不仅有效实现了状态收敛, 同时能够渐近逼近并学习观测噪声的真实边界。相较于自适应概率滤波方法, 所提出的方法将估计误差降低了约 10%, 进一步推动了集员滤波技术在复杂实际场景中的工程化应用和部署。

关键词: 自适应集员滤波(ASMF); 不确定性变量; 线性离散时间系统; 未知噪声; 渐近有界跟踪

中图分类号: V217　　**文献标志码:** A　　**文章编号:** 2095-8110(2026)03-0025-10

An adaptive set-membership filtering method for linear discrete-time systems

LI Yudong[1], DONG Jiuxiang[1], CONG Yirui[2]

（1. College of Information Science and Engineering, Northeastern University, Shenyang 110819, China;
2. College of Intelligence Science and Technology, National University of Defense Technology, Changsha 410073, China）

Abstract: Extreme weather conditions, electromagnetic interference, and other complex environmental disturbances are widely encountered in practical engineering applications. These factors introduce significant model uncertainties, which cause traditional navigation and estimation systems to suffer from performance degradation or even filter divergence due to their reliance on accurate prior models. Most critically, such uncertainties are often unmeasurable, time-varying, and lack reliable statistical prior information during actual operation, posing substantial challenges to robust state estimation. To address this problem, an adaptive set-membership

收稿日期: 2026-01-19; **修订日期:** 2026-03-19
基金项目: 国家自然科学基金(62273079); 流程工业综合自动化国家重点实验室(中国)研究基金(2013ZCX01)
作者简介: 李育东(1996—), 男, 博士研究生, 主要从事集员滤波方面的研究。
通信作者: 董久祥(1978—), 男, 博士, 教授, 主要从事容错控制与故障诊断模糊系统、集员估计、多智能体协同控制方面的研究。

filtering（ASMF）framework is proposed to solve the open problem of state estimation for linear discrete-time systems under completely unknown bounded noise priors. Unlike traditional set-membership filtering methods that depend on fixed noise boundaries， the proposed framework introduces uncertain variables for system modeling. The worst-case boundary information of the measurement noise is progressively extracted from the measurement data sequence based on the system model， enabling the iterative learning and adaptive identification of the unknown observation noise characteristics. Based on this，the filter dynamically adjusts the estimation set to gradually approach the true state， achieving asymptotically bounded tracking of the system state. An adaptive filtering algorithm based on constrained zonotopes is designed， an extensible theoretical framework is established，and its stability analysis is completed. Simulation experiments verify that the proposed method maintains stable estimation performance in unknown disturbance environments. It not only effectively achieves state convergence but also asymptotically approaches and learns the true boundaries of the observation noise. Compared with the adaptive probabilistic filtering method，the proposed method reduces the estimation error by approximately 10%，further advancing the engineering application and deployment of set-membership filtering technology in complex practical scenarios.

Key words：Adaptive set-membership filtering（ASMF）；Uncertain variable；Linear discrete-time system；Unknown noise；Asymptotic bounded tracking

0 引言

在滤波问题中，面对信号不准确的挑战性环境，近似的噪声分布无法准确表征模型的不确定性。不恰当的数值会导致滤波性能急剧下降，甚至使滤波结果发散。针对上述情况，自适应扩展卡尔曼滤波（adaptive extended Kalman filter, AEKF）目前被认为是一种处理系统时变噪声的有效方法。文献 [1] 和文献 [2] 基于期望最大化算法，提出了一种改进的变分自适应卡尔曼滤波（adaptive Kalman filter, AKF），用于先验信息不准确情况下的自主水下航行器协同定位。文献 [3] 提出了一种高精度无人机定位系统，该系统在狭窄环境中将惯性测量单元（inertial measurement unit, IMU）和超宽带（ultra-wideband, UWB）与 AEKF 进行融合。虽然 AEKF 增强了算法对时变噪声的鲁棒性[4-5]，但其输出的置信度指标从根本上依赖于理想的高斯假设。在涉及非高斯噪声或模型不匹配的实际场景中，这些指标往往过于乐观或不可靠。因此，基于概率方法的定位结果不能作为安全关键决策（如避障或着陆）的唯一依据。

当定位任务需要可靠的结论，且噪声的统计特性未知但范围已知时，可采用集员滤波（set-membership filter, SMF）方法来解决。与贝叶斯滤波类似，SMF 也包含预测步骤（利用系统函数下的集合像，在线性系统中表现为闵可夫斯基和）和更新步骤（利用集合交集）。在这一经典的 SMF 框架下，后续及现有的研究主要聚焦于如何针对不同集合表示方法推导出精确解或近似解，其主要可分为以下两类。

1）椭球型集员滤波器：这类滤波器利用椭球体外边界近似闵可夫斯基和与集合交集。文献 [6] 提出了一种连续−离散时间椭球型集员滤波器，用于估计外部边界，其结构与卡尔曼滤波器类似。在类似的系统设定下，文献 [7] 通过求解相应的黎卡提方程，研究了滤波与平滑问题。文献 [8-9] 提供了用于最小化椭球体闵可夫斯基和与交集外边界体积的算法。在文献 [10] 中，针对线性离散时间系统，推导出了体积最小化和迹最小化的椭球型外边界（每种均由两个椭球体描述）。文献 [11] 将外边界的描述推广到了多个椭球体。

2）全对称多胞形（zonotope）型集员滤波器：这类滤波器利用凸 zonotope 描述或界定外边界，以完成预测和更新过程。与椭球型滤波器不同，zonotope 型滤波器可为线性滤波问题导出精确解，因为 zonotope 在闵可夫斯基和与集合交集运算下是封闭的。文献 [12] 提出了递归最优边界平行 zonotope 算法，以给出精确解的外边界。文献 [13] 设计了一种针对线性离散时间系统的 zonotope 型集员滤波器，利用基于奇异值分解的近似方法。文献 [14] 提出一种针对非线性离散时间系统的 zonotope 型集员滤波器，其中利用凸优化推导了 zono-

tope 外边界。文献 [15] 使用两个凸函数之差的规划方法，对 zonotope 型集员滤波器的状态更新过程进行了改进。

目前，SMF 在一部分实际系统中有着广泛的应用。文献 [16] 提出了一种车道边界增强的集员全球卫星导航系统定位方法；文献 [17] 提出了一种全局 SMF 方法，基于分布式定位网络实现了自动导引车的准确定位；文献 [18] 提供了一种约束凸生成器方法，通过切割测量环处理二维距离测量的非凸性；文献 [19-20] 提出了基于 SMF 的安全关键定位系统，能够实时在线测量并估计位置的可靠性。然而，传统的 SMF 通常假设噪声边界是固定且已知的，这一前提在动态的无人机场景中往往难以实现。在这种情况下，经典 SMF 的静态边界会导致一个两难困境：过宽的边界会使估计结果过于保守且精度较差，而过窄的边界则存在遗漏真实状态的风险，导致滤波失效。因此，在保持严格可靠性的同时实现对动态噪声的适应性，是一个尚未解决的关键问题。当前尚无有效的 SMF 算法能够处理时变噪声边界。该领域的现有研究很大程度上局限于解决抗异常值问题或针对固定边界的鲁棒性问题[21-22]，而针对动态不确定性进行自适应调整的方法尚未得到探索。另外，信号处理领域中的集合自适应滤波方法，如文献 [23-25] 所涉及的参数集合线性回归问题，也未能很好地解决噪声不确定情况下线性系统的 SMF 问题（参见文献 [26] 的例子 3.1）。

为解决上述问题，开发了一种新颖的自适应集员滤波（adaptive set-membership filter, ASMF）框架，其主要贡献如下。

实现了观测噪声边界的在线迭代学习：现有的 SMF 方法通常依赖于对噪声边界的精确先验假设。本研究的创新之处在于，引入了一种全新机制，利用不确定性变量对系统进行建模，并通过在线迭代学习的方式，分析系统模型测量值中所包含的观测噪声边界信息。该方法能够动态地估计和更新噪声边界，从而无需人工干预和先验设定，即可逐步实现状态估计的收敛。

多维 ASMF 算法：针对 SMF 中的集合表示问题，本研究设计了基于带约束全对称多胞形（constrained zonotopes, CZ）的自适应滤波算法，并完成了其稳定性分析，为该类方法在复杂系统中的应用提供了理论支撑。

1　问题描述

1.1　预备知识

对于样本空间 Ω，从 Ω 到可测集 X 的可测函数 $\boldsymbol{x}:\Omega\to X$ 被称为不确定变量，其取值范围 $[\![\boldsymbol{x}]\!]$ 定义如下

$$[\![\boldsymbol{x}]\!]:=\{\boldsymbol{x}(\omega):\omega\in\Omega\} \tag{1}$$

$$D(S)=\sup_{s,s'\in S}\|s-s'\| \tag{2}$$

表示集合 S 的直径。对于具有连续下标的多个不确定性变量，定义

$$\boldsymbol{x}_{k_1:k_2}=\boldsymbol{x}_{k_1},\cdots,\boldsymbol{x}_{k_2} \tag{3}$$

给定欧几里得空间中的两个集合 S_1 和 S_2，运算符 $\oplus$ 表示 S_1 和 S_2 的闵可夫斯基和。

1.2　系统模型

考虑如下基于不确定性变量的线性离散系统

$$\boldsymbol{x}_{k+1}=\boldsymbol{A}\boldsymbol{x}_k+\boldsymbol{B}\boldsymbol{w}_k \tag{4}$$

$$\boldsymbol{y}_k=\boldsymbol{C}\boldsymbol{x}_k+\boldsymbol{v} \tag{5}$$

状态方程式（4）描述了系统状态随时间的变化规律，其中 $\boldsymbol{w}_k$ 为过程噪声/动态噪声，其边界已知。测量方程式（5）描述了系统状态是如何被测量的，其中 $\boldsymbol{y}_k$ 代表测量值，$\boldsymbol{v}$ 代表测量噪声，其边界有界但未知。

1.3　ASMF 问题

基于不确定性变量的经典 SMF 框架可表示如下。

初始化：系统状态 0 时刻先验值，过程噪声，测量噪声的边界分别为 $[\![\boldsymbol{x}_0]\!],[\![\boldsymbol{w}_k]\!],[\![\boldsymbol{v}_k]\!]$。

步骤 1：预测

$$[\![\boldsymbol{x}_k|y_{0:k-1}]\!]=\boldsymbol{A}[\![\boldsymbol{x}_{k-1}|y_{0:k-1}]\!]\oplus\boldsymbol{B}[\![\boldsymbol{w}_{k-1}]\!] \tag{6}$$

步骤 2：更新

$$[\![\boldsymbol{x}_k|y_{0:k}]\!]=\ker(\boldsymbol{C})\oplus\boldsymbol{C}+([\![\boldsymbol{v}_k]\!]\oplus\{y_k\})\cap[\![\boldsymbol{x}_k|y_{0:k-1}]\!] \tag{7}$$

步骤 3：循环上述步骤。

$\ker(\cdot)$ 表示矩阵的零空间。对于实际情况下的 SMF 问题而言，其 $\boldsymbol{v}$ 的先验信息往往是未知的（测量噪声的边界未知）。ASMF 的目标是在没有任何测量噪声先验信息的情况下，确定系统状态在给定噪声序列 $y_{0:k}:=y_0,\cdots,y_k$ 下的集合估计 $X_k(y_{0:k})$。与经典的 SMF 类似，该集合估计满足如下条件。

1）非空

$$X_k(y_{0:k})\neq\varnothing \tag{8}$$

2）渐近有界：集合估计和真实状态的豪斯多夫

距离为

$$d_k^{\mathrm{g}}(X_k(y_{0:k})) := d_{\mathrm{H}}(X_k(y_{0:k}), [\![\boldsymbol{x}_k|y_{0:k}]\!])$$
$$d_{\mathrm{H}}(\boldsymbol{S},\boldsymbol{T}) = \max\{\sup_{s\in S}\inf_{t\in T}\|s-t\|, \sup_{t\in T}\inf_{s\in S}\|s-t\|\} \quad (9)$$

满足

$$\overline{\lim_{k\to\infty}} d_k^{\mathrm{g}}(X_k(y_{0:k})) < \infty \quad (10)$$

2 线性离散系统自适应滤波框架

2.1 观测值中的噪声边界信息

为处理$\boldsymbol{v}$先验信息未知的问题，通过引入另一个不确定性变量，将其重写为

$$[\![\boldsymbol{v}]\!] = t_k[-1,1], \quad t_k \in [\![\boldsymbol{t}_k]\!] \quad (11)$$

其中，$\boldsymbol{t}_k$为测量噪声在k时刻的边界，用不确定性变量表示。将$\boldsymbol{t}_k$看作系统状态，令

$$\bar{\boldsymbol{x}}_k = \mathrm{col}(\boldsymbol{x}_k, \boldsymbol{t}_k) \quad (12)$$

可得到基于式(4)和式(5)的增广系统如下

$$\begin{aligned}\bar{\boldsymbol{x}}_{k+1} &= \bar{\boldsymbol{A}}\bar{\boldsymbol{x}}_k + \bar{\boldsymbol{B}}\boldsymbol{w}_k \\ \boldsymbol{y}_k &= \bar{\boldsymbol{C}}\bar{\boldsymbol{x}}_k\end{aligned} \quad (13)$$

其中

$$\begin{aligned}&\bar{\boldsymbol{A}} = \mathrm{diag}(\boldsymbol{A},1), \bar{\boldsymbol{B}} = \mathrm{col}(\boldsymbol{C},0), \\ &\bar{\boldsymbol{C}} = [\boldsymbol{C}, \mathrm{diag}(t_k)], t_k \in [-1,1]\end{aligned} \quad (14)$$

$\mathrm{diag}(\boldsymbol{v})$代表由向量$\boldsymbol{v}$中元素组成对角线的方阵。基于经典 SMF 方法，对增广系统执行经典 SMF 操作，算法步骤见表 1。

表 1 对增广系统的 SMF

Tab. 1 SMF for augmented systems

算法 1: 经典SMF		
1. 初始化	$[\![\bar{\boldsymbol{x}}_0]\!] = [\![\boldsymbol{x}_0]\!] \times [\![\boldsymbol{t}_0]\!], [\![\boldsymbol{t}_0]\!] = [0,+\infty)$	(15)
2. 当$k\neq 0$	$[\![\bar{\boldsymbol{x}}_k|y_{0:k-1}]\!] = \bar{\boldsymbol{A}}[\![\bar{\boldsymbol{x}}_{k-1}|y_{0:k-1}]\!] \oplus \bar{\boldsymbol{B}}[\![\boldsymbol{w}_{k-1}]\!]$	(16)
3. 更新	$[\![\bar{\boldsymbol{x}}_k|y_{0:k}]\!] = \bigcup_{\xi\in[-1,1]} (\ker([\boldsymbol{C},\xi]) + [\boldsymbol{C},\xi]^+\{y_k\}) \cap [\![\bar{\boldsymbol{x}}_k|y_{0:k-1}]\!]$	(17)
4. 循环上述步骤		

对增广的系统状态做 SMF 的几何解释如图 1 所示。图 1 中，d为当前时刻观测值到先验估计的距离。左边的灰色三角区域表示先验值的范围，右边的灰色三角区域表示由观测值约束构成的范围。由红色线包围的集合描述了增广系统状态在k时刻的滤波结果。可以看出，$\boldsymbol{t}_k$的范围是存在下界的，这表明虽然每一时刻噪声边界的上界是未知的，但通过不断迭代学习，SMF 能够逐步确定观测噪声边界的下界(即最坏情况)。根据这一发现，可以构造一种 ASMF 框架。

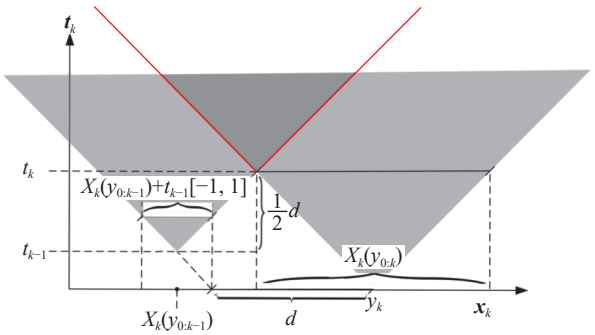


图 1 ASMF 的几何解释

Fig. 1 Geometric interpretation of ASMF

2.2 离散线性系统的 ASMF 框架

2.2.1 一维 ASMF 框架

构造一维 ASMF 框架如表 2 所示。

表 2 一维 ASMF 算法

Tab. 2 One dimension ASMF algorithm

算法 2: 一维ASMF		
1. 初始化	$[\![\boldsymbol{v}]\!] = t_0[-1,1], t_0 = 0$	(18)
2. 当$k\neq 0$	$[\![\boldsymbol{x}_k|y_{0:k-1}]\!] = a[\![\boldsymbol{x}_{k-1}|y_{0:k-1}]\!] \oplus b[\![\boldsymbol{w}_{k-1}]\!]$	(19)
3. 判断是否	$y_k \in c[\![\boldsymbol{x}_k|y_{0:k-1}]\!] \oplus [\![\boldsymbol{v}]\!] = Y_k$	(20)
是	$[\![\boldsymbol{x}_k|y_{0:k}]\!] = \frac{1}{c}(y_k \oplus [\![-\boldsymbol{v}]\!]) \cap [\![\boldsymbol{x}_k|y_{0:k-1}]\!]$，$t_k = \beta t_{k-1}$	(21)
否	$t_k = t_{k-1} + (y_k - \mathrm{center}(Y_k)) - \frac{1}{2}\mathrm{length}(Y_k)$, $[\![\boldsymbol{v}]\!] = t_k[-1,1], [\![\boldsymbol{x}_k|y_{0:k}]\!] = y_k \oplus [\![-\boldsymbol{v}]\!]$	(22)
4. 循环步骤2~3		

首先，算法将动态观测噪声及其边界初始化为零。步骤 1 为 ASMF 算法的预测步骤，基于系统方程给出系统状态的先验值，a,b,c为相应的系统矩阵退化为一维形式。步骤 2 为更新步，先判断观测值是否在基于上一步观测噪声求得的理论观测范围内。若判断结果为真，则正常执行 SMF 过程，此时测量噪声边界以$0<\beta<1$为衰减因子进行衰减；若判断结果为假，则对观测噪声边界t_k进行更新。从图 1 可以看出，每次更新观测噪声边界时，其增量和Y_k的中点$\mathrm{center}(Y_k)$、长度$\mathrm{length}(Y_k)$有着明确的数学关系。通过这个数学关系可以计算出新的噪声边界t_k，并利用这个新的边界进行下一步的 SMF 过程。

2.2.2 基于 CZ 的多维离散线性系统的 ASMF 框架

基于 CZ 这一集合表示形式，将 2.2.1 小节的一维 ASMF 方法扩展至适用于多维线性离散系统。CZ 这类集合表示方法具有如下定义。

定义 1. 如果存在一个参数五元组

$$(\hat{\boldsymbol{G}},\hat{c},\hat{\boldsymbol{A}},\hat{b},\hat{h})\in\mathbf{R}^{n\times n_{\mathrm{g}}}\times\mathbf{R}^{n}\times\mathbf{R}^{n_{\mathrm{c}}\times n_{\mathrm{g}}}\times\mathbf{R}^{n_{\mathrm{c}}}\times[0,\infty]^{n_{\mathrm{g}}} \tag{23}$$

使得集合$S\subseteq\mathbf{R}^{n}$可表示为

$$\left\{\hat{\boldsymbol{G}}\xi+\hat{c}:\hat{\boldsymbol{A}}\xi=\hat{b},\xi\in\prod_{j=1}^{n_{\mathrm{g}}}\left[-\hat{h}^{(j)},\hat{h}^{(j)}\right]\right\}=:Z(\hat{\boldsymbol{G}},\hat{c},\hat{\boldsymbol{A}},\hat{b},\hat{h}), \tag{24}$$

其中，$\hat{h}^{(j)}$表示$\hat{h}$的第j个分量。那么这个集合被称为 CZ。对于上述集合描述方法，引入如下引理来描述空间内任意单点在各个维度上对 CZ 的投影区间。

引理 1. 考虑多维 CZ: $Z=Z(\hat{\boldsymbol{G}},\hat{c},\hat{\boldsymbol{A}},\hat{b},\hat{h})\subset\mathbf{R}^{n}$，对于空间内任意单点$x$，其在$Z$的第$i$维上的投影区间可表示为

$$(Z)^{(i)}(x)=Z(\hat{\boldsymbol{G}}^{(i)},\hat{c}^{(i)},\hat{\boldsymbol{A}}^{(i)},\hat{b}^{(i)},\hat{h}^{(i)}) \tag{25}$$

其中

$$\hat{\boldsymbol{G}}^{(i)}=(\hat{\boldsymbol{G}})_{i,:},\hat{c}^{(i)}=(\hat{c})_{i,:},\hat{\boldsymbol{A}}^{(i)}=\begin{bmatrix}\hat{\boldsymbol{A}}\\(\hat{\boldsymbol{G}})_{/i,:}\end{bmatrix},$$

$$\hat{b}^{(i)}=\begin{bmatrix}\hat{b}\\\boldsymbol{x}^{(/i)}-(\hat{c})_{/i,:}\end{bmatrix},\hat{h}^{(i)}=\begin{bmatrix}\hat{h}\\\mathbf{1}_{m-1,1}\end{bmatrix}$$

其中：$(\cdot)_i,(\cdot)_{/i}$分别表示矩阵的第i行和除第i行之外的所有行；$\boldsymbol{x}^{(/i)}$表示除第i维外x的其他维度组成的矢量；$\mathbf{1}_{m,n}$和$\mathbf{0}_{m,n}$分别为m乘n维且元素为 1 和 0 的矩阵。

图 2 描述了引理 1 中投影区间的几何意义。应用上述引理，可以计算观测值与系统状态先验值之间的距离，从而实现对观测噪声逐维的自适应估计。相应的多维 ASMF 算法见表 3。

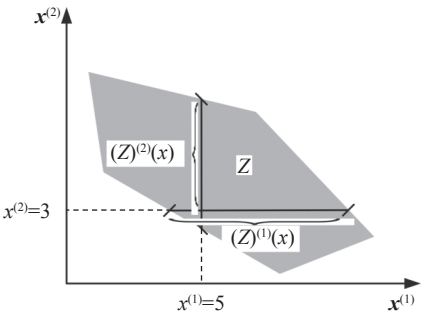


图 2　单点在 CZ 上投影区间的几何解释

Fig. 2　Geometric interpretation of the projection interval of a single point onto a constrained zonotope

表 3　基于 zonotope 的 ASMF 算法

Tab. 3　Zonotope-based ASMF algorithm

算法 3: 基于zonotope的ASMF

1. 初始化: 测量信号序列和过程噪声

$$\begin{aligned}&y_{0:k},Z_k^{w}=Z(\hat{\boldsymbol{G}}^{w},\hat{c}^{w},\hat{\boldsymbol{A}}^{w},\hat{b}^{w},\hat{h}^{w})\\&\boldsymbol{I}_0=Z(\hat{\boldsymbol{G}}^{I},\hat{c}^{I},\hat{\boldsymbol{A}}^{I},\hat{b}^{I},\hat{h}^{I}),t_0=0_{m,1}\\&\hat{\boldsymbol{G}}^{I}=\mathrm{diag}(t_0),\hat{c}^{I}=0_{m,1},\hat{\boldsymbol{A}}^{I}=[],\hat{b}^{I}=[],\hat{h}^{I}=1_{m,1}\end{aligned} \tag{26}$$

2. 当$k=0$

$$\begin{aligned}&Z_0=\ker(\boldsymbol{C})+\boldsymbol{C}+(\{y_0\}+\boldsymbol{I}_0)=Z(\hat{\boldsymbol{G}},\hat{c},\hat{\boldsymbol{A}},\hat{b},\hat{h})\\&\hat{\boldsymbol{G}}=\begin{bmatrix}\boldsymbol{N}&\boldsymbol{C}+\boldsymbol{G}^{I}\end{bmatrix},\hat{c}=\boldsymbol{C}+(y+c^{I}),\hat{\boldsymbol{A}}=\begin{bmatrix}0&\boldsymbol{A}^{I}\end{bmatrix},\hat{b}=b^{I},\hat{h}=h^{I}\end{aligned} \tag{27}$$

3. 当$k\neq0$, 循环$i=1\to m$

$$\begin{aligned}&Y_k^{(i)}=(Y_k)^{(i)}(x),Y_k=\boldsymbol{C}(\boldsymbol{A}Z_{k-1}+\boldsymbol{B}Z_{k-1}^{w})+\boldsymbol{I}_{k-1}=Z(\hat{\boldsymbol{G}}^{y},\hat{c}^{y},\hat{\boldsymbol{A}}^{y},\hat{b}^{y},\hat{h}^{y})\\&\hat{\boldsymbol{G}}^{y}=\begin{bmatrix}\boldsymbol{C}\boldsymbol{A}\hat{\boldsymbol{G}}^{x}&\boldsymbol{C}\boldsymbol{B}\hat{\boldsymbol{G}}^{w}&\hat{\boldsymbol{G}}^{I}\end{bmatrix},\hat{c}^{y}=\boldsymbol{C}(\boldsymbol{A}\hat{c}^{x}+\boldsymbol{B}\hat{c}^{w})+\hat{c}^{I}\\&\hat{\boldsymbol{A}}^{y}=\begin{bmatrix}\hat{\boldsymbol{A}}^{x}&0&0\\0&\hat{\boldsymbol{A}}^{w}&0\\0&0&\hat{\boldsymbol{A}}^{I}\end{bmatrix},\hat{b}^{y}=\begin{bmatrix}\hat{b}^{x}\\\hat{b}^{w}\\\hat{b}^{I}\end{bmatrix},h_y=\begin{bmatrix}\hat{h}^{x}\\\hat{h}^{w}\\\hat{h}^{I}\end{bmatrix}\end{aligned} \tag{28}$$

判断是否$y_k^{(i)}\in Y_k^{(i)}$

是

$$t_k^{(i)}=\beta t_{k-1}^{(i)} \tag{29}$$

否

$$t_k^{(i)}=t_{k-1}^{(i)}+\mathrm{Abs}(y_k^{(i)}-\mathrm{center}(Y_k^{(i)}))-\frac{1}{2}\mathrm{length}(Y_k^{(i)}) \tag{30}$$

4. 更新测量噪声

$$\begin{aligned}&\boldsymbol{I}_k=Z(\hat{\boldsymbol{G}}^{I},\hat{c}^{I},\hat{\boldsymbol{A}}^{I},\hat{b}^{I},\hat{h}^{I}),\\&\hat{\boldsymbol{G}}^{I}=\mathrm{diag}(t_k),\hat{c}^{I}=0_{m,1},\hat{\boldsymbol{A}}^{I}=[],\hat{b}^{I}=[],\hat{h}^{I}=1_{m,1}\end{aligned} \tag{31}$$

续表

算法 3: 基于zonotope的ASMF

5. 若t_k未发生变化

$$
\begin{aligned}
&Z_k^- = \boldsymbol{A}Z_{k-1} + \boldsymbol{B}Z_{k-1}^w = Z(\hat{\boldsymbol{G}}^-, \hat{c}^-, \hat{\boldsymbol{A}}^-, \hat{b}^-, \hat{h}^-)\\
&\hat{\boldsymbol{G}}^- = \begin{bmatrix} \boldsymbol{A}\hat{\boldsymbol{G}} & \boldsymbol{B}\hat{\boldsymbol{G}}^w \end{bmatrix}, c_k^- = \boldsymbol{A}\hat{c}_{k-1} + \boldsymbol{B}\hat{c}^w,\\
&\hat{\boldsymbol{A}}^- = \begin{bmatrix} \hat{\boldsymbol{A}} & 0 \\ 0 & \hat{\boldsymbol{A}}^w \end{bmatrix}, \hat{b}^- = \begin{bmatrix} \hat{b} \\ \hat{b}^w \end{bmatrix}, \hat{h}^- = \begin{bmatrix} \hat{h} \\ \hat{h}^w \end{bmatrix},\\
&Z_k = [\ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_k\} + \boldsymbol{I}_k)] \cap (Z_k^-) = Z(\hat{\boldsymbol{G}}, \hat{c}, \hat{\boldsymbol{A}}, \hat{b}, \hat{h})\\
&\hat{\boldsymbol{G}} = \hat{\boldsymbol{G}}^-, \quad \hat{c}_k = \hat{c}^-, \ \hat{\boldsymbol{A}}_k = \begin{bmatrix} \hat{\boldsymbol{A}}^- & 0 \\ 0 & \hat{\boldsymbol{A}}^I \\ \boldsymbol{C}\hat{\boldsymbol{G}}^- & \hat{\boldsymbol{G}}^I \end{bmatrix}, b_k = \begin{bmatrix} \hat{b}^- \\ \hat{b}^I \\ y_k - \hat{c}^I - \boldsymbol{C}\hat{c}^- \end{bmatrix}, \hat{h}_k = \begin{bmatrix} \hat{h}^- \\ \hat{h}^I \end{bmatrix}
\end{aligned} \tag{32}
$$

否则

$$
\begin{aligned}
&Z_k = \ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_k\} + \boldsymbol{I}_k) = Z(\hat{\boldsymbol{G}}, \hat{c}, \hat{\boldsymbol{A}}, \hat{b}, \hat{h})\\
&\hat{\boldsymbol{G}} = \begin{bmatrix} \boldsymbol{N} & \boldsymbol{C}+\boldsymbol{G}^I \end{bmatrix}, \hat{c} = \boldsymbol{C}+(y_k + c^I), \hat{\boldsymbol{A}} = \begin{bmatrix} 0 & \boldsymbol{A}^I \end{bmatrix}, \hat{b} = b^I, \hat{h} = h^I
\end{aligned} \tag{33}
$$

6. 循环步骤3~5

算法 3 基于真实观测值与观测值先验范围在每个维度的投影距离对观测噪声进行自适应更新。首先，初始化测量噪声范围为I_0。当$k=0$时，算法将系统观测值作为先验。当$k>0$时（步骤 3），算法先判断观测值y_k的各个维度是否被Y_k包含，如果均被包含，则以β为衰减因子对观测噪声的边界进行衰减。若不被包含，则按式（31）更新测量噪声。在步骤 5 中，若观测噪声未发生变化，则执行预测−更新步骤；若发生变化，则只做更新步骤，进而得到系统状态估计Z_k。其中，$\boldsymbol{N}$为$\ker(\boldsymbol{C})$中的一组基矩阵，$\boldsymbol{C}^+$代表矩阵$\boldsymbol{C}$的伪逆。

2.2.3 稳定性证明

针对所提出的 ASMF 算法 3，存在如下定理。

定理 1. 对于系统（式（4）和式（5）），所提出的 ASMF 满足式（8）~式（10）的稳定性要求。

证明：

非空：当$k=0$时

$$Z_0 = \ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_0\} + \boldsymbol{I}_0) \neq \varnothing \tag{34}$$

当$k>0$时，且$y_k \in Y_k$，意味着

$$Z_k = [\ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_k\} + \boldsymbol{I}_k)] \cap (\boldsymbol{A}Z_{k-1} + \boldsymbol{B}Z_{k-1}^w) \neq \varnothing \tag{35}$$

这表明对于任意的$k \in \mathbf{N}_0$，有

$$Z_k \neq \varnothing \tag{36}$$

渐近有界：根据自适应滤波框架和经典 SMF 框架，系统实际状态范围和 ASMF 估计范围分别满足

$$
\begin{aligned}
[\![\boldsymbol{x}_k | y_{0:k}]\!] =& [\ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_k\} + [\![-\boldsymbol{v}]\!])] \cap \\
& (\boldsymbol{A}[\![\boldsymbol{x}_k | y_{0:k-1}]\!] + \boldsymbol{B}Z_{k-1}^w),\\
X_k(y_{0:k}) =& Z_{k-1} = [\ker(\boldsymbol{C}) + \boldsymbol{C}+(\{y_k\} + \boldsymbol{I}_k)] \cap \\
& (\boldsymbol{A}Z_{k-1} + \boldsymbol{B}Z_{k-1}^w)
\end{aligned} \tag{37}
$$

其中，$\boldsymbol{I}_k$为估计的观测噪声。当 $\boldsymbol{I}_k \subseteq [\![\boldsymbol{v}]\!]$时，依据三角不等式有

$$\overline{\lim_{k\to\infty}} d_k^{\mathrm{g}}(X_k(y_{0:k})) < \infty \tag{38}$$

当$\boldsymbol{I}_k \supseteq [\![\boldsymbol{v}]\!]$时，根据自适应滤波框架，$\boldsymbol{I}_k$不再增长，也有

$$\overline{\lim_{k\to\infty}} d_k^{\mathrm{g}}(X_k(y_{0:k})) < \infty \tag{39}$$

因此，当$k \in \mathbf{N}_0$，该 ASMF 框架满足渐近有界要求。证毕。

3 仿真实验

为验证所提 ASMF 算法在系统中的有效性和鲁棒性，设计了仿真实验，主要针对系统状态的估计精度、噪声抑制能力及算法收敛性进行测试。

3.1 状态估计与跟踪性能

实验在标准仿真环境下进行，考虑如下一维线性离散系统

$$
\begin{aligned}
&\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \boldsymbol{w}_k,\\
&\boldsymbol{y}_k = \boldsymbol{x}_k + \boldsymbol{v},\\
&[\![\boldsymbol{w}_k]\!] = [-1, 1], \quad [\![\boldsymbol{v}_k]\!] = [-1, 1]
\end{aligned} \tag{40}
$$

其中，$\boldsymbol{x}_k$为第k秒时刻的位移（单位：m）。为测试算法在测量噪声未知情况下的性能，人为设置了时变的测量噪声，以系统的真实状态作为基准，将其与滤波输出进行对比。主要评估指标包括状态估计范围（估计区间）及对测量噪声幅值的在线估计值。并且，将所提算法与现有方法进行了对比。

图 3 展示了 ASMF 对系统（式（40））的状态估计结果。其中，红点代表系统的真实状态，蓝线代表算法的滤波输出。从图 3 可以看出，滤波结果能够紧密跟踪真实状态的变化趋势。即使在真实状

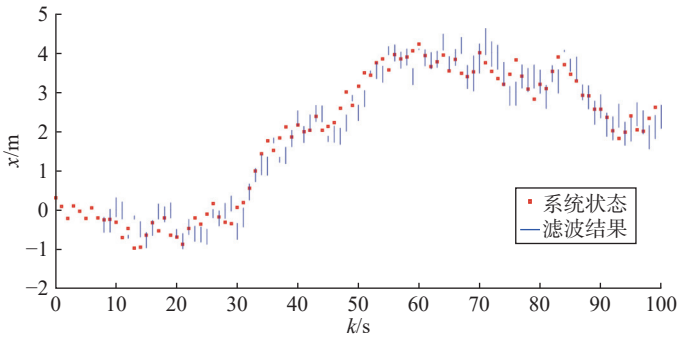


图 3　ASMF 状态估计的效果

Fig. 3　Effect of ASMF state estimation

态发生剧烈波动的区间，算法依然保持了良好的跟踪能力，未出现明显的滞后或发散。

3.2　测量噪声估计性能

图 4 展示了 1 000 组蒙特卡罗实验下算法对系统（式（40））状态估计的噪声幅值均值变化。绿线代表算法在线估计出的噪声幅值均值。在 $k = 50$ s 之前，真实噪声幅值为 1 m，而后降为 0.6 m。算法通过自适应机制调整，能够学习估计值的上界，并能在真实噪声变化后稳步改变至新的水平。这种对噪声统计特性的在线辨识能力，是本算法区别于传统固定噪声假设滤波器的核心优势，有效避免了因噪声先验不准确导致的次优估计。

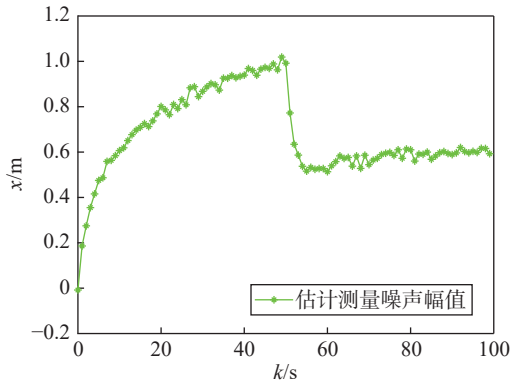


图 4　ASMF 的测量噪声估计效果

Fig. 4　Measurement noise estimation performance of ASMF

3.3　与现有方法的比较

基于 1 000 次蒙特卡罗实验，图 5 对比了 4 种不同滤波算法对系统（式（40））的平均估计误差表现。其中，ASMF 在估计精度与自适应能力上展现出显著优势。对于准确和不准确的 SMF 而言，分别设定其观测噪声幅值为 1 m 和 1.5 m。相较于文献 [3] 中的传统 AKF（误差始终高于 0.4 m）及不准确的 SMF（固定误差约 0.4~0.48 m），ASMF 的初始误差虽略高（约 0.5 m），但能在动态环境中持续优化，误差逐步降至 0.25~0.3 m 区间并趋于稳定。这一趋势不仅优于两种基准方法，还体现出良好的收敛性和鲁棒性。即便初始模型不精确，ASMF 也能通过自适应机制有效降低误差，接近准确的 SMF 所达到的理想性能（误差为 0.2~0.25 m），在模型存在不确定性或环境动态变化的实际场景中极具应用价值。

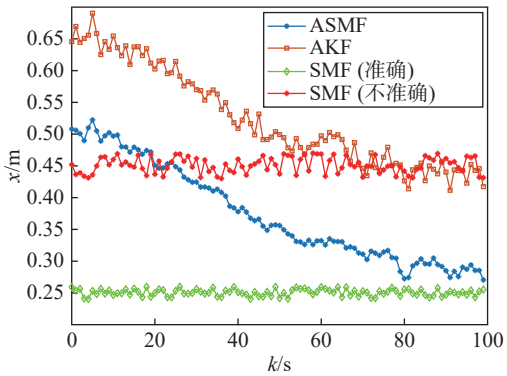


图 5　4 种不同滤波算法的估计误差表现

Fig. 5　Estimation error performance of four different filtering algorithms

3.4　定量比较

将所提方法与文献 [3] 中的 AKF 方法及经典 SMF 方法进行了估计误差的均方根误差（root mean square error, RMSE）和估计范围大小的平均值的定量比较，结果见表 4。

表 4　与其他方法的定量比较

Tab. 4　Quantitative comparison with other methods

算法名称	估计误差RMSE/m	估计范围大小的平均值/m
ASMF	0.387	0.319
AKF	0.452	—
经典SMF（准确）	0.363	0.251
经典SMF（不准确）	0.392	0.471

从 RMSE 指标可见：ASMF 在稳定性上表现较好，其 RMSE 为 0.387 m，表明该算法在迭代过程中能有效抑制噪声并快速逼近真实状态。相较于 AKF，ASMF 的估计误差减少了约 10%（对于不同系统，效果可能不太相同）。AKF 表现较差，其 RMSE 为 0.452 m，由于未引入集员约束，在非高斯噪声或模型失配的情况下，其表现略逊于 ASMF，且无法给出状态估计范围。经典 SMF 缺乏自适应机制，在噪声先验未知的情况下，如果噪声范围设计不准，不准确的 SMF 的效果要劣于本文提出的 ASMF 方法。综上，在相同仿真条件下，ASMF 在估计精度和鲁棒性方面显著优于传统 SMF 方法，尤其适用于对实时性和准确性要求较高的应用场景。

3.5 多维 ASMF 仿真

针对多维线性系统对算法 3 进行仿真。基于系统（式（4）和式（5）），考虑一个实际场景的跟踪问题，具体如下

$$\begin{aligned}&\boldsymbol{A}=\boldsymbol{I}_3,\boldsymbol{C}=\boldsymbol{I}_3,\boldsymbol{B}=\boldsymbol{I}_3,\\&[\![\boldsymbol{w}_k]\!]=[-1,1]^6,[\![\boldsymbol{v}]\!]=[-1,1]^3\end{aligned}\tag{41}$$

目标在三维场景下移动，系统状态 $\boldsymbol{x}_k=\left[\begin{array}{ccc}\boldsymbol{x}_k^{(1)} & \boldsymbol{x}_k^{(2)} & \boldsymbol{x}_k^{(3)}\end{array}\right]^{\mathrm{T}}$ 为其在 3 个坐标轴下的坐标（单位：m）。当 $[\![\boldsymbol{v}]\!]$ 未知时，应用算法 3 可得到图 6 的轨迹滤波结果，其中红色区域为状态估计 CZ 的区间外包，黑线为真实轨迹。可以看出，ASMF 能很好地跟踪任务目标。

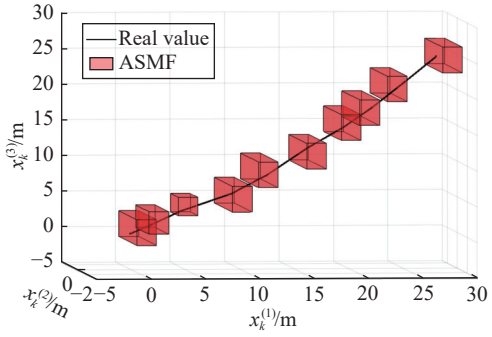


图 6 多维 ASMF 仿真效果

Fig. 6 Simulation results of multidimensional ASMF

其次，基于系统（式（4）和式（5）），考虑一个 6 维的无人机轨迹重构问题，以展示 ASMF 在复杂动态系统中的效果。其系统参数如下

$$\begin{aligned}&\boldsymbol{A}=\left[\begin{array}{cc}1 & \Delta t_k\\0 & 1\end{array}\right]\otimes\boldsymbol{I}_3,\boldsymbol{C}=\left[\begin{array}{cc}1 & 0\end{array}\right]\otimes\boldsymbol{I}_3,\boldsymbol{B}=\boldsymbol{I}_6,\\&\boldsymbol{w}_k=[-1,1]^6,\boldsymbol{v}_k=[-1,1]^3\end{aligned}\tag{42}$$

无人机在三维空间中运动，其状态向量可表示为

$$\boldsymbol{x}_k=\left[\begin{array}{cccccc}\boldsymbol{x}_k^{(1)} & \boldsymbol{x}_{v,k}^{(1)} & \boldsymbol{x}_k^{(2)} & \boldsymbol{x}_{v,k}^{(2)} & \boldsymbol{x}_k^{(3)} & \boldsymbol{x}_{v,k}^{(3)}\end{array}\right]^{\mathrm{T}}\tag{43}$$

其中，$\boldsymbol{x}_k^{(i)},\boldsymbol{x}_{v,k}^{(i)}\in\mathbf{R}$ 分别代表第 i 个维度的位置（单位：m）和速度（单位：m/s）。$\Delta t_k=1$ s 为采样间隔。配置经典 SMF 方法的观测噪声为 $[-1.5,1.5]^3$ m，得到在 1 000 次蒙特卡罗平均下的估计误差对比效果如图 7 所示。可以看出，与经典 SMF 方法相比，ASMF 方法在噪声未知的情况下能够逐渐实现更精确的状态观测。

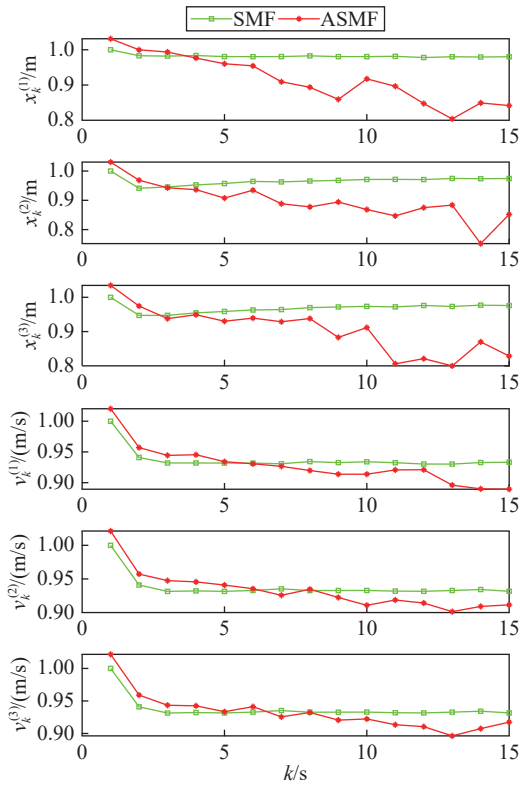


图 7 6 维无人机轨迹重构问题仿真效果

Fig. 7 Simulation results of 6-dimensional trajectory reconstruction for unmanned aerial vehicles

4 结论

本文提出了一种鲁棒的 ASMF 框架。

1）该框架摒弃了对噪声先验分布的强假设，引入不确定性变量对系统进行建模，构建了一种适用于噪声信息未知的线性离散系统的 ASMF 机制。它通过在线迭代学习观测值中蕴含的噪声边界信息，动态更新噪声约束集，进而自适应调整滤波过程，在无需先验知识的条件下有效维持状态估计的有界性。

2）仿真实验结果表明，所提方法能够实现对系

统状态的渐近有界跟踪，显著提升了滤波器在不确定性环境下的鲁棒性与稳定性。相较于概率自适应滤波方法，本文所提方法在不确定性噪声环境下将估计误差降低了约 10%。

本框架不仅为含噪系统的状态估计提供了可行解决方案，更可作为拓展至高维复杂系统的理论基础，推动 SMF 技术向实际工程应用落地迈进。未来工作将聚焦于将该自适应机制推广至非线性与高维系统，并结合多源融合导航架构，进一步提升其在真实复杂场景中的适应能力与实用性。

参考文献

[1] HUANG Y，ZHANG Y，XU B，et al. A new adaptive extended Kalman filter for cooperative localization[J]. IEEE Transactions on Aerospace and Electronic Systems，2017，54(1)：353-368.

[2] HUANG Y，BAI M，LI Y，et al. An improved variational adaptive Kalman filter for cooperative localization[J]. IEEE Sensors Journal，2021，21(9)：10775-10786.

[3] YANG B，YANG E，YU L，et al. Adaptive extended Kalman filter-based fusion approach for high-precision UAV positioning in extremely confined environments[J]. IEEE/ASME Transactions on Mechatronics，2022，28(1)：543-554.

[4] 郝广俊，林思超，连阳林，等. LSTM-EKF 融合的电磁阵列定位方法 [J]. 导航定位与授时，2025，12(6)：112-122.
HAO Guangjun，LIN Sichao，LIAN Yanglin，et al. Electromagnetic array positioning method based on LSTM-EKF fusion[J]. Navigation Positioning and Timing，2025，12(6)：112-122 (in Chinese).

[5] 戴捷，郑沛，张爱军，等. 最大相关熵平方根容积卡尔曼滤波在 GNSS-RTK 定位中的应用 [J]. 导航定位与授时，2025，12(3)：59-67.
DAI Jie，ZHENG Pei，ZHANG Aijun，et al. Application of maximum correntropy square root volume Kalman filter in GNSS positioning[J]. Navigation Positioning and Timing，2025，12(3)：59-67 (in Chinese).

[6] SCHWEPPE F. Recursive state estimation：unknown but bounded errors and system inputs[J]. IEEE Transactions on Automatic Control，1968，13(1)：22-28.

[7] BERTSEKAS D，RHODES I. Recursive state estimation for a set-membership description of uncertainty[J]. IEEE Transactions on Automatic Control，1971，16(2)：117-128.

[8] CHERNOUSKO F L. Optimal guaranteed estimates of indeterminacies with the aid of ellipsoids. Parts I-III[J]. Engineering Cybernetics，1980，18(5)：1-7.

[9] FOGEL E，HUANG Y. On the value of information in system identification —bounded noise case[J]. Automatica，1982，18(2)：229-238.

[10] MAKSAROV D G，NORTON J P. State bounding with ellipsoids under model uncertainty[J]. International Journal of Control，1996，65(5)：847-866.

[11] DURIEU C，WALTER É，POLYAK B. Multi-input multi-output ellipsoidal state bounding[J]. Journal of Optimization Theory and Applications，2001，111(2)：273-303.

[12] CHISCI L，GARULLI A，ZAPPA G. Recursive state bounding by parallelotopes[J]. Automatica，1996，32(7)：1049-1055.

[13] COMBASTEL C. A state bounding observer based on zonotopes[C]// Proceedings of European Control Conference. Piscataway：IEEE，2003：2589-2594.

[14] ALAMO T，BRAVO J M，CAMACHO E F. Guaranteed state estimation by zonotopes[J]. Automatica，2005，41(6)：1035-1043.

[15] ALAMO T，BRAVO J，REDONDO M，et al. A set-membership state estimation algorithm based on DC programming[J]. Automatica，2008，44(1)：216-224.

[16] BENTO L C，BONNIFAIT P，NUNES U J. Set-membership position estimation with GNSS pseudorange error mitigation using lane-boundary measurements[J]. IEEE Transactions on Intelligent Transportation Systems，2018，20(1)：185-194.

[17] YANG H，ZHANG Y，GU W，et al. A novel global set-membership filtering approach for localization of automatic guided vehicles[J]. IEEE Transactions on Industrial Informatics，2022，19(3)：3219-3228.

[18] SILVESTRE D. Constrained convex generators：a tool suitable for set-based estimation with range and bearing measurements[J]. IEEE Control Systems Letters，2021，6：1610-1615.

[19] ZHOU B，ZHU Y，RUI C，et al. Safety-critical ultra-wideband 3D localization with set-membership uncertainty representation[J]. IEEE Robotics and Automation Letters，2025，10(9)：8826-8833.

[20] QIN X，CONG Y，LAI J，et al. Single-beacon localization for mobile robot：a set membership filtering approach[J]. IEEE Robotics and Automation Letters，2024，9(11)：9899-9906.

[21] ZHU H，AMURI M J V，SHEN J，et al. Mean-shift-based robust distributed set-membership fusion filtering for sensor network systems with outliers[J]. Automatica，2025，177：112345.

[22] CONG Y，WANG X，ZHOU X. Stability of linear set-membership filters with respect to initial conditions：an observation-information perspective[J]. Automatica，2025，172：111993.

[23] GOLLAMUDI S，NAGARAJ S，KAPOOR S，et al. Set-membership filtering and a set-membership normalized LMS algorithm with an adaptive step size[J]. IEEE Signal Processing Letters，1998，5(5)：111-114.

[24] DE LAMARE R C，DINIZ P S R. Set-membership adaptive algorithms based on time-varying error bounds for CDMA interference suppression[J]. IEEE Transactions on Vehicular Technology，2008，58(2)：644-654.

[25] YAZDANPANAH H，LIMA M V S，DINIZ P S R. On the robustness of set-membership adaptive filtering algorithms[J]. EURASIP Journal on Advances in Signal Processing，2017，2017(1)：72.

[26] SÄRKKÄ S，SVENSSON L. Bayesian filtering and smoothing[M]. Cambridge：Cambridge University Press，2023.

（编辑：黄利华）